




20260903进展汇报

LLM-based KGR验证与Agent Memory Benchmark

汇报人：魏熙润

Knowledge Science and Engineering Laboratory



问题背景


Knowledge Science and Engineering Laboratory



为什么需要 LLM-based KGR



- 复杂问题通常需要跨多个实体与关系进行多跳推理，不能只靠单跳检索或实体匹配
- 知识图谱提供显式关系结构，适合做路径级别的解释、约束满足与结果验证
- 图谱规模大、候选路径多，容易出现搜索空间爆炸、噪声扩展和错误累积，因此需要更强的推理组织能力
- LLM-based KGR可以利用 LLM 的语义理解与推理能力，更高效地在 KG 上完成多跳推理与答案生成



两种范式

Knowledge Science and Engineering Laboratory



Retrieval-based vs Synergy-based

现有 LLM-based KGR 方法分为 retrieval-augmented 与 synergy-augmented 两类



Query: Which company is Amazon's competitor in the global marketplace?

(a) Retrieval-augmented methods





LLM

Prompt: Based on the retrieved paths, please answer the question.

Answer: Walmart

(b) Synergy-augmented methods




LLM

Iterative path retrieval (beam search, width=2)

Prompt: Based on the retrieved paths, please answer the question.

Answer: Walmart



核心流程：检索三元组/路径/子图 $\rightarrow$ LLM推理

优点：


- 流程清晰，检索推理分离
- 解释性强，可以追溯检索路径
- 成本较低，调用LLM次数有限

局限性：

- 检索质量决定上限，漏召回或者噪声路径会影响LLM生成质量
- 无法根据中间推理结果动态调整

Question:

What is the majority party now in the country where **Canberra** is located?




核心流程：LLM 根据当前推理状态动态决定下一步 KG 查询，KG 返回结果后，LLM 继续迭代推理

优点：

- 推理灵活：根据中间结果调整查询策略
- 适合复杂多跳推理：逐步探索推理路径

局限性：

- 成本高：多次 LLM 调用增加成本
- 搜索控制难：如何决定何时停止



(b) Path Prioritization


核心流程：用优先级函数对当前实体 e 打分，优先扩展更有价值的推理路径。

$$d(q, e) = \sum_{\pi \in \Pi_{q \rightsquigarrow e}} d(\pi)$$

从问题到当前实体 e 的所有路径中，已经积累的语义路径价值。

$$f(e, a) = f([d(q, e), q])$$


基于当前状态 $d(q, e)$ 和问题 q ，估计从当前实体继续搜索，到达正确答案的潜力。



KG-Agent

Knowledge Science and Engineering Laboratory

问题动机：已有 synergy-based 往往依赖预定义交互流程，且依赖强闭源模型；同时，这类复杂交互往往依赖 **GPT-4** 等强闭源模型，小模型难以直接胜任。




核心原理

- **Planner (LLM)**：根据当前状态决定下一步调用哪个工具。
- **Toolbox + Executor**：把 KG 推理拆成可执行的结构化操作，而不是纯文本推理。
- **Knowledge Memory**：保存当前 KG 信息和历史推理程序，支持下一步决策。

优点：





- 只用10K instruction samples 微调 LLaMA-7B，。就能在多项数据集上超过更大模型或更多数据的方法



Agentic Reasoning


Knowledge Science and Engineering Laboratory

Agent 问题不再只是某个单一任务，而是一个包括方法、工具、评测、现实问题和应用的生态。



Question

As of Q4 2024, A mid-sized retailer, X operates 50 stores across the southwestern U.S. and aims to reduce overstocking costs by 10% while still maintaining at least 98% product availability for its top-selling items during the upcoming holiday quarter. how can X Retail forecast next quarter's optimal inventory levels per store to balance cost minimization against high service levels?



Mind Map

LLM Models



Reasoning...

I need to identify Relevant External Economic Indicators [Web-Search]

...

To model demand volatility amid inflation and shifting consumer sentiment, I need to search historical sales under relevant economic indicators. [Web-Search]...

Then, we can use ARIMAX with external regressors to predict per-store sales [Code] ...

...

So putting this all together, the strategies would be [Mind Map]

Tools



Query: US Q4 2024 Inflation and CCI

Searching...

...As of Q4 2024, the United States inflation rate stands at 2.7%, the Consumer Confidence Index (CCI) is at 109

Coding...

Query: Use ARIMAX to predict Q4 per-store sales given...

Searching...

Result: The projected sales will be...

```

...SARIMAX( sales,
exog=[cci, inflation],
order=(1,1,1), seasonal_order=(0,1,1,4))
results = model.fit()
exog_future =
pd.DataFrame({"cci":
[115], "inflation": [3.5]},
index=[pd.Timestamp("2025-03-31")])
Forecast = ...
  
```

核心组件

- **Reasoning LLM:** 负责主推理，决定何时调用何种工具。
- **Tool Agents:** 扩展外部能力：搜索、代码、API。
- **Structured Memory:** Mind-Map 维护长链推理上下文。




两个想要考虑尝试的切入点

Agentic Reasoning 中的成本问题:

- 长链推理导致消耗大量Token
- 工具调用次数太频繁
- 多轮交互时延迟过高

Agentic Reasoning 中的记忆问题:

- 长链推理容易失上下文
- 存储的记忆不一定对规划有帮助



KGR实验验证

Knowledge Science and Engineering Laboratory



EoG / BoG: 创新集中在探索策略，而非子图检索



Explore-on-Graph (EoG)

- ▶ 动机：规则约束或固定示范路径限制 OOD 泛化与新路径探索。
- ▶ Stage 1: 用长 CoT / 图探索轨迹进行 SFT 冷启动。
- ▶ Stage 2: GRPO + final-answer correctness, 并用 path information 细化过程奖励。
- ▶ 重点：鼓励多样、有效的自主探索，减少无意义路径。

explore broader

Backjump-on-Graph (BoG)

- ▶ 动机：query 想象的关系路径与真实 KG 拓扑不匹配，Agent 容易进入 dead end。
- ▶ Stage 1: 合成含 Forward / Backjump / Yield / Halt 的轨迹进行 SFT。
- ▶ Stage 2: RL 优化回跳时机与落点；混合奖励抑制冗余转移并奖励正确答案。
- ▶ 重点：从历史状态非局部回跳，再探索替代分支。

recover from dead ends

共同空缺：仍未显式把同一候选 **action/path** 竞争建模为 **ranking problem**，也未解决 **memory** 何时有益或有害。



KGR最小闭环：从候选动作到记忆门控



验证目标

- ▶ 先验证候选空间中是否存在可学习的排序信号，再验证小模型能否稳定输出动作。
- ▶ 比较 no-memory / random-memory / verified-memory，判断跨样本经验是否真正改变策略。
- ▶ 训练轻量 gate，检验“何时用 memory”能否接近 oracle，而非默认把 memory 拼进 prompt。

结论：闭环跑通，但性能瓶颈依次暴露在检索覆盖、记忆门控和排序到策略的转化。



瓶颈首先出现在子图构建



0.15

初始候选关系召回

SELECT ?r ?o LIMIT 50 被元数据
关系和重复对象占满



0.86

修复后候选召回

关系级采样 + namespace过滤;
eval100

0.94

边召回

目标关系相关边进入候选子图;
eval100

0.62

答案可见率

即使关系召回较高，答案实体仍只
在62%子图中可见

错误认识

只要后续推理策略更强，就能解决 **KGQA**。


实际：检索漏召回会直接截断答案路径，**policy** 无法恢复不存在的证据。

得到的设计约束

- ▶ 必须报告 candidate recall / answer visibility。
- ▶ 推理改进必须与检索上限分开归因。
- ▶ gold subgraph 只能作为 oracle，不是公平主设定。




0.6B模型：SFT能学会动作格式，memory增益很小



说明小模型可用于验证受控 **action policy**，但不能把格式学习误判为 **memory** 有效。

Memory ablation / Acc@1



+1 / 60

verified memory 相比 no-memory 只多答对 1 个样本

结论：直接拼接 memory 不是稳定创新点，真正的问题是选择、抑制与更新。



Memory不是单调增益：是否使用比有没有更关键



逐样本因果现象

6
helped
memory纠正

5
hurt
memory误导

38
both right
是否注入均正确

11
both wrong
候选/能力有限

Gate策略 / Acc@1



Oracle gap 说明“选择性使用”有空间；**GRM-lite** 失败说明样本与状态表征不足。



排序奖励：pairwise学会比较，但尚未转化为Top-1



Method	Top-1	MRR	R@3	R@5	PrefAcc
rule	.10	.193	.20	.30	.494
memory	.49	.606	.71	.73	.821
pointwise LR	.47	.598	.72	.75	.881
pairwise LR	.40	.553	.70	.75	.911
listwise RRF	.33	.485	.59	.73	.842

.911

Pairwise preference accuracy

能区分 hard negative

≠ Top-1提升

Pairwise Top-1 = .40, 低于 memory heuristic = .49; 简单 listwise 融合继续下降。

排序信号适合作为过程奖励/诊断信号，但还需要 **policy coupling** 才能改进最终答案。



KGR实验给出的真实结论



1 Retrieval ceiling

答案不可见时，后续RL/GRPO无法补回证据；必须拆分检索与推理贡献。

2 Non-monotonic memory

memory 对不同样本既有帮助也会误导；平均分掩盖了 use/suppress 决策。

3 Gate learning is the bottleneck

oracle 0.8167，但轻量GRM只有0.6833；缺少可诊断的memory state supervision。

4 Ranking is not policy

pairwise比较正确并不等于Top-1与答案正确；需要闭环状态、动作与后果。

研究转向：不再把 memory 当额外文本，而是把“状态、使用、抑制、修复”本身变成可测对象。



Agent Memory Benchmarks

Knowledge Science and Engineering Laboratory



Agent Memory: 评测对象不是长上下文本身



Agent memory = 跨交互持续存在、可被写入/检索/使用/更新，并影响未来行为的认知状态。



区别 RAG主要回答“从外部知识库检索什么”；长上下文主要回答“窗口内能放多少”；Agent Memory还必须回答“哪些状态可被未来行为信任、何时应被抑制或修复”。



经典Memory Benchmark的演进



演进主线 检索到事实 → 跨会话记忆 → 多类型能力 → 战略选择 → 由记忆驱动工具行动

仍缺少统一的、受控的 **memory-state intervention**: 同一个任务仅改变 **stale/conflicting/incomplete/verified memory** 后, **Agent** 是否会改变行为?



经典工作对照：测到了什么，还没测什么




Benchmark	Memory source	Core task	Primary signal	Remaining gap
CRAG	Web / KG API	factual QA	accuracy / hallucination	非持久memory lifecycle
LoCoMo	长对话事件	QA / summary	long-range recall	不控制memory状态
LongMemEval	历史会话	5类memory能力	QA accuracy	以回答为终点
StratMem	must/nice/irr池	条件响应生成	使用/抑制/整合	不执行环境动作
Mem2Act	长期任务链	tool + parameters	tool-call accuracy	缺少verify/repair闭环

共同盲区：aggregate accuracy 很难定位记忆到底在形成、检索、使用还是更新环节失败。

The first four works are explicitly discussed in the StratMem-Bench introduction/related work.



StratMem-Bench: 从“记住事实”到“战略使用”



Input $x_i = (h_i, q_i, P_i, M_i)$

must

保证事实正确，缺失会导致错误

nice

非必需但可增加个性、共情与连贯

irr

与当前目标无关，应主动抑制

Output 角色一致且有策略的回复
 $\hat{y}$

四个指标

- ▶ SMC: required memory 是否全部满足
- ▶ MIQ: 使用后的整合质量
- ▶ PES: supportive memory 的增益
- ▶ CIR: 无条件引入 irrelevant memory 的比例

关键发现

模型通常能区分
must 与 **irr**

但加入 **nice** 后，
“用多少、怎么用”显著变难

启示: memory evaluation 要测 selective deployment, 不只是 recall。



近邻工作把评测推向行动，但仍彼此割裂



Mem2ActBench

从长期记忆恢复 **tool** 与参数

离线 tool call; 未纳入 verify / clarify / repair

MemFail

分解 **summarization / storage / retrieval**

诊断组件失败; 未测行动时的memory regulation

AuthMem-Bench

测试 **consolidation** 后 **authority collapse**

聚焦来源权限; 未统一覆盖read/use/repair

SafeCommit

commit / probe / fallback 下的安全证书

proof-of-concept latent worlds; 未接真实memory stack

MobileMem

一年尺度移动经历与多模态个人记忆

覆盖更新/偏好, 但不是受控matched intervention

机会不是再拼一个更大的任务集合，而是用 **matched memory-state family** 连接 **diagnosis** → **control** → **repair**。



MemReadyBench

Knowledge Science and Engineering Laboratory



核心问题：记忆状态何时足以支持下一步行动？



在持久记忆可能陈旧、冲突、不完整或受污染时，**Agent** 能否诊断其可用性、调控其影响，并在验证后修复记忆以支持未来会话？

RQ1

Memory-state diagnosis

Agent 能否识别当前记忆是 verified、stale、conflicting、incomplete 还是 corrupted？

RQ2

Memory-use control

在不同风险与证据状态下，能否选择 USE / SUPPRESS / CLARIFY / VERIFY / ABSTAIN？

RQ3


Prospective repair

获得权威反馈后，能否修复持久记忆，并在下一session稳定复用？

与StratMem的边界：它测“给定memory池如何表达”；这里测“memory状态变化是否改变工具决策，并能否被修复”。



MemReadyBench: Stage-I Benchmark for Memory Diagnosis, Use, Repair, and Longitudinal Evaluation



Primary Metrics



MSFA

Memory-State Family Accuracy



VCS

Verified Closure Success



PMCR

Premature Memory-Grounded Commit Rate



LRU

Longitudinal Repair Utility



NAR

Normalized Acquisition Regret



Benchmark输入、过程与输出



- 1 Canonical world** 构造真实世界 w^* 、历史 H 、用户目标 q 与允许动作集合 A 。
- 2 Matched memory states** 固定任务与世界，仅干预 M : verified / stale / conflict / incomplete / corrupted。
- 3 Black-box agent** 接入被测 memory backend + LLM agent; 不泄露memory标签。
- 4 Action trajectory** 记录 retrieve、use/suppress、clarify/verify、commit/abstain 与tool结果。
- 5 Session-C probe** 权威反馈后进入新会话，检查修复后的memory能否稳定影响未来行动。

核心控制变量：同一实例族只改变 **memory state**，因此能把行为变化归因于记忆，而不是任务难度。



四类任务：同一实例族中的诊断、控制与修复



T1

Memory Diagnosis

判断每条memory的状态、来源与缺失证据；输出结构化标签。

T2

Memory-Use Control

在matched states下选择 USE / SUPPRESS / CLARIFY / VERIFY / ABSTAIN。

T3

Closure & Execution

证据充分时才提交带副作用的动作；否则执行低风险信息获取。

T4

Memory Repair

验证世界后更新/删除/降权旧memory，并在Session C测试未来复用。

四类任务不是四个互不相关的数据集，而是同一memory episode上的逐层探针。



五个主指标：同时看状态、行为与未来收益



MSFA **Memory-State Factor Accuracy** 对memory状态因子的宏平均准确率；避免多数类掩盖stale/conflict失败。

VCS **Verified Closure Score** 只有在证据充分且行动正确时得分；惩罚premature commit。

PMCR **Paired Memory Causal Responsiveness** 同一实例不同memory state下，策略是否按预期改变。

LRU **Lifecycle Repair Utility** 修复前后在Session C的未来任务收益差。

NAR **Negative-memory Avoidance Rate** 面对错误/污染记忆时，成功抑制其影响的比例。

主张成立的最低条件：不仅总体分下降，还要在 **matched pairs** 上出现方向正确、统计稳定的策略变化。



最小可行实验与Go / No-Go



Pilot配置

- ▶ 200-300个canonical episodes, 每个生成3-5种matched memory states。
- ▶ 3类领域: 日程/沟通、文件与知识工作、受约束的工具调用。
- ▶ Baselines: long-context、RAG、直接memory reader、StratMem-style selector、SafeCommit wrapper。
- ▶ 至少3个backbone + 2个memory backend; 报告效果、成本、延迟与拒答率。

GO memory-state intervention 产生显著、可复现的PMCR; 错误能被归因到diagnosis/control/repair中的具体环节。

NO-GO 模型对memory state不敏感、指标主要复刻最终准确率, 或自动标注无法被人工稳定复核; 此时先收缩问题而不是扩数据。

Stage II训练暂不进入框架图: 只有Stage I证明存在稳定诊断信号后, 才设计memory controller或RL。



参考文献：LLM-based KGR



- [1] Pan, S. et al. (2024). Unifying Large Language Models and Knowledge Graphs: A Roadmap. IEEE TKDE. doi:10.1109/TKDE.2024.3352100.
- [2] Sun, J. et al. (2024). Think-on-Graph: Deep and Responsible Reasoning of Large Language Model on Knowledge Graph. ICLR 2024. openreview.net/forum?id=nnVO1PvbTv.
- [3] Luo, L., Li, Y.-F., Haffari, G., & Pan, S. (2024). Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning. ICLR 2024. openreview.net/forum?id=ZGNWW7xZ6Q.
- [4] Jiang, J. et al. (2025). KG-Agent: An Efficient Autonomous Agent Framework for Complex Reasoning over Knowledge Graph. ACL 2025, 9505-9523. doi:10.18653/v1/2025.acl-long.468.
- [5] Wu, J., Zhu, J., Liu, Y., Xu, M., & Jin, Y. (2025). Agentic Reasoning: A Streamlined Framework for Enhancing LLM Reasoning with Agentic Tools. ACL 2025, 28489-28503. doi:10.18653/v1/2025.acl-long.1383.
- [6] Liu, Y. et al. (2026). PathMind: A Retrieve-Prioritize-Reason Framework for Knowledge Graph Reasoning with Large Language Models. AAAI 40(18), 15386-15393. doi:10.1609/aaai.v40i18.38565.
- [7] Yan, S. et al. (2026). Explore-on-Graph: Incentivizing Autonomous Exploration of LLMs on KGs with Path-refined Reward Modeling. ICLR 2026. arXiv:2602.21728.
- [8] Zhang, Y. et al. (2026). Backjump-on-Graph: Empowering LLMs with Reinforced Retrospective Exploration for Agentic KGR. ICML 2026, PMLR 306.



参考文献：Agent Memory Benchmarks



- [1] Yang, X. et al. (2024). CRAG - Comprehensive RAG Benchmark. NeurIPS 2024 Datasets and Benchmarks Track, 10470-10490. doi:10.52202/079017-0335.
- [2] Maharana, A. et al. (2024). Evaluating Very Long-Term Conversational Memory of LLM Agents. ACL 2024, 13851-13870. doi:10.18653/v1/2024.acl-long.747.
- [3] Wu, D. et al. (2025). LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. ICLR 2025. arXiv:2410.10813.
- [4] He, J. et al. (2025). MADial-Bench: Towards Real-World Evaluation of Memory-Augmented Dialogue Generation. NAACL 2025, 9902-9921.
- [5] Hu, Y. et al. (2025). Memory in the Age of AI Agents. arXiv:2512.13564.
- [6] Wu, Y., Wu, T., Zhu, M., Sha, H., & Wang, H. (2026). StratMem-Bench: Evaluating Strategic Memory Use in Virtual Character Conversation Beyond Factual Recall. ACL 2026, 32309-32328. doi:10.18653/v1/2026.acl-long.1491.
- [7] Shen, Y., Li, K., Zhou, W., & Hu, S. (2026). Mem2ActBench: Evaluating Long-Term Memory Utilization in Task-Oriented Autonomous Agents. ACL 2026. aclanthology.org/2026.acl-long.370.
- [8] Garg, I., Kolhe, N., Song, D., & Zhao, X. (2026). MemFail: Stress-Testing Failure Modes of LLM Memory Systems. arXiv:2605.26667.
- [9] Zhan, Q. et al. (2026). When Memory Becomes Authority: Benchmarking Authority Collapse at the Memory Consolidation Boundary. arXiv:2608.01679.
- [10] Akewar, M., & Ranjan, R. (2026). SafeCommit: Certifying When Memory-Grounded Agents May Safely Act. arXiv:2608.04289.



请各位批评指正！