

REVISED AFTER 2026 ARXIV COLLISION AUDIT

MemReadyBench

持久记忆 Agent 的来源感知行动准备度评测

Evaluating Source-Aware Action Readiness in Persistent-Memory Agents

核心转向

不再争夺“记忆是否足够”的首创，
而是诊断缺失证据位于哪里、应向哪个权威来源路由、
何时才可以执行。

MEMORY

WORLD

USER

EXECUTION

一句话问题

Agent 能否识别
尚未闭合的行动
条件，找到它的
可信来源，并在
产生外部副作用
前完成证据闭合
？

Benchmark first
Method second

2026-09-03

审稿式重判：方向继续，首创表述必须更换

8.5/10

问题重要性

5/10

原问题新颖性

8/10

修订 Benchmark

5/10

当前 Controller

8.5/10

资源可行性

不能再主张

首次提出 memory sufficiency、safe commitment、ask/verify/abstain、paired executable evaluation 或 memory operation as action。

仍可主张

来源感知 readiness、决定性证据来源迁移、动作翻转与闭合收敛、真实 memory stack 的逐层 oracle 诊断。

最大风险

被审稿人理解为 SafeCommit + MCB + AgentAbstain 的组件拼接；必须用因果 family 和新发现消除这一印象。

Decision: CONDITIONAL GO · 先做 20-task source-relocation pilot, 再决定是否扩展。

为什么只看顶会会得出错误的新颖性判断

公开优先权

预印本一旦公开，问题、术语和实验设计就会进入审稿人的 prior art; target venue 不是 accepted，但不能忽略。

同期速度

SafeCommit、Router-Mem、MCB 都在 2026 年 8 月出现；只扫描已接收列表会错过最直接竞争者。


审查单位

不能只比标题；必须逐项核对 problem、action space、gold、counterfactual、execution 与 limitation。

本次检索的三层路径

01	直接问题词	memory sufficiency · safe commitment · verify/ask · abstention
02	邻近机制词	tool necessity · clarification · provenance · memory skepticism
03	反向核验	从最接近论文的 limitation 倒推仍未覆盖的交叉点

2026 同期时间线：原问题空间在半年内迅速拥挤



结论：会议接收列表是滞后视图；选题检查必须把最新 arXiv 当成正式竞争集合。

SafeCommit: 最直接竞争者，也是必须正面承认的边界

它已经做了什么

在 stale、conflicting、incomplete、corrupted memory 下构造 plausible worlds；只有 proposed action 在保留世界中均安全才 commit，否则 probe 或 fallback。

与原方案重叠

行动前充分性、premature commitment、风险-成本权衡、主动探测、确定性 simulator 与失败分解几乎全部重叠。

它明确留下什么

作者把评测定位为 proof-of-concept：显式小 world set、固定动作与 safety map、确定性二值 probe，未系统测试真实 memory stack。

写作上必须改变的句子

不要写

We are the first to ask whether memory is sufficient to act.

改成

We diagnose where unresolved action requirements can be authoritatively resolved and whether agents route acquisition correctly.

竞争矩阵：每个旧卖点都已经有了明确邻居

工作	已有核心	与本方向的关键边界
SafeCommit	commit / probe / fallback	小型显式 worlds; 非真实 memory stack 诊断
MCB	persist / local / verify / ask	写入边界; 不执行 acquisition 与下游 action
AgentAbstain	paired act/abstain + sandbox	干预 instruction/tool/env, 而非持久记忆来源
Router-Mem / InfMem	sufficiency router + memory control	QA/效率; 无 memory/world/user 来源路由
SURE-RAG	set-level evidence sufficiency	RAG answer verification, 不是外部副作用行动
MemSyco-Bench	memory skepticism / conflict	聚焦迎合, 不统一测缺失证据获取
MemCon / Oblivion	memory operation policy	是待测方法, 不提供统一 decision-point gold

创新不能落在组件，要落在尚未被共同覆盖的交叉点

已被覆盖

- evidence sufficiency / retrieve-or-stop
- safe commitment / probe / fallback
- verify world / ask user
- act-abstain paired tasks
- memory operation as action
- stale / conflict / poison / authority
- setwise verifier 与风险校准

仍可形成统一贡献

Persistent

交互生成、跨 session

Source-aware

memory / world / user

Counterfactual

移动决定性证据来源

Decision gold

readiness / requirement / action

Executable

获取后闭合并验证终态

Diagnostic

oracle 分离系统瓶颈

修订后的研究问题：Source-Aware Action Readiness

给定历史交互形成的持久记忆、当前工作 packet 和 world/user 接口，Agent 能否识别尚未闭合的行动条件，定位其权威来源，并在外部副作用发生前选择正确的信息获取或承诺动作？

WHAT IS MISSING?

哪个 requirement 尚未闭合？

WHERE IS IT?

packet、memory、world、user
还是不可得？

WHAT NEXT?

search、verify、ask、execute 还是
abstain？

DID IT CLOSE?

获取后是否收敛到可验证行动？

SafeCommit 判断 proposed action 是否可认证；MemReadyBench 评测真实 Agent 能否发现缺口、找到来源并达到可执行闭合。

两层状态、五个动作、四类 Gold


行动准备度



缺失证据来源



控制动作



核心数据资产：Source × Integrity 因子化反事实

SOURCE LOCATION



INTEGRITY



不是机械做全笛卡尔积：generator 只生成语义成立的组合。关键是同一 requirement 在来源或完整性变化后，正确动作发生可预测翻转。

Matched Family 示例：只移动 “最终授权” 的可信来源

共同目标 为用户预订满足历史偏好的航班；航班、日期、预算和最终购买授权必须全部闭合。

PACKET	本轮明确授权	EXECUTE
MEMORY	历史会话含有效授权	SEARCH_MEMORY
WORLD	企业审批系统记录当前授权	VERIFY_WORLD
USER	只有用户能给一次性授权	ASK_USER
UNAVAILABLE	无人/无系统可确认	ABSTAIN

ACTION FLIP：第一动作不同 → CLOSURE CONVERGENCE：可解决版本最终预订结果相同

三个 Track：从诊断到顺序获取，再到真实执行



Track A 是低成本诊断；Track B/C 才能证明这不是静态分类任务。

四组指标：重点新增 Routing 与 Closure

MONITOR

Readiness Macro-F1
Missing Requirement F1
Source Location F1
Closure F1
Brier / ECE

ROUTING

Source-Routing Acc.
Wrong-Source Rate
Location Regret
Calls-to-Closure
Admissible Action Acc.

COUNTERFACTUAL


Action-Flip Consistency
Closure-Convergence
Integrity Sensitivity
Distractor Invariance
Surface Robustness

OUTCOME + COST

Exact Tool State
Premature Commit
Unsupported Success
Unnecessary Acquisition
Success-Cost Pareto


不发布单一总分：同样的 task success 可能来自正确闭合，也可能来自猜测或越权执行。

Baseline 梯子：要能回答错误到底发生在哪一层



公平约束：固定 backbone、tool schema、可见 source、token、调用次数和 wall-clock budget。

实验不是只跑主表，而是逐层证明 benchmark 的诊断价值



可证伪假设

- H1 最终成功率会高估 readiness/routing，因为存在猜测与 unsupported success。
- H2 强模型在 Memory / World / User 来源迁移下仍表现出惯性动作。
- H3 FullHistory 能减少 SEARCH 错误，但不能解决 WORLD/USER routing，并放大 stale/poison 风险。
- H4 memory controller 的 success 提升不保证 wrong-source 与 premature commit 降低。

两周最小闭环：先过生死线，再扩数据

20**BASE TASKS**

calendar + travel

120+**EPISODES**

source families

3**ACQUISITION APIs**

memory / world / user

0**TRAINING**

pilot first

2**WEEKS**


Go / No-Go

必须通过的 Gate


- OracleAll 可解率 $\geq 98\%$ ，且 80% 以上指标可由 deterministic evaluator 计算。
- FullHistory 与简单 prompt 不能在跨来源 family 上接近 oracle。
- 至少两个 baseline 呈现不同的 routing / cost / premature trade-off。
- source relocation 稳定触发正确 action flip; paraphrase 与 distractor 不应触发翻转。
- 成功 acquisition 后，可解决版本的最终 action 和环境终态能够 closure-converge。

No-Go: 如果 FullHistory + prompt 已饱和，或 VERIFY_WORLD 与 ASK_USER 无法自然区分，就停止扩展。

方法放在第二阶段：训练“来源迁移”，不是再拼一个通用 Controller



训练顺序



Reward closure + correct route + exact outcome – acquisition cost – premature commit – unsupported success

MVP 不需要独立 GRM: symbolic gold 与环境 validator 已提供可验证信号。

可以主张什么，绝对不能主张什么

DEFENSIBLE CLAIMS

- source-aware action readiness 的统一定义
- Source × Integrity matched counterfactual families
- action flip + closure convergence 双重协议
- 真实 memory stack 的 decision-point joint gold
- monitor / routing / retrieval / execution oracle 分解
- 可重采样、可执行的任务与 validator

CLAIMS TO AVOID

- 首次研究 memory sufficiency
- 首次提出 safe commitment
- 首次引入 ask / verify / abstain
- 首次做 paired executable tasks
- 首次把 memory operation 当 action
- 首次处理 stale / conflict / poison
- 首次做 setwise evidence verification

论文主线：从“能否回忆”推进到“能否找到正确证据来源后再行动”

01 Prior work Recall、strategic use、safe commitment、abstention 和 memory control 已分别成熟。

02 Missing layer 真实 Agent 同时面对 memory、world、user 等来源，却缺少来源感知 readiness 诊断。

03 Benchmark 用 source relocation 改变正确 acquisition action，并用 integrity stress 增加风险。

04 Protocol 逐决策点 joint gold + action flip + closure convergence + exact execution。

05 Finding 揭示不同模型和 memory stack 在 monitor、routing、retrieval、execution 的独立瓶颈。

Benchmark 的价值不在多一个排行榜，而在说明 Agent 为什么在错误的来源上继续找，或为什么过早执行。

最终建议：有条件继续，先完成最小闭环

CONTINUE

问题重要，数据与评测
路线可行，四卡 4090
不是主要瓶颈。

CONDITIONAL GO

NOW

实现 20-task
pilot
验证 source
relocation 与
closure

NEXT

扩展到 300–500
tasks
比较真实
memory stacks

LATER

仅在暴露
routing
bottleneck 后
训练 source-
aware
controller

第一道生死线：强模型是否仍会在正确来源之间路由失败。

同期直接竞争与关键邻近工作

完整撞题矩阵、状态与 limitation 见配套审计报告

01

SafeCommit
[arXiv 2608.04289 · 2026-08-04 · https://arxiv.org/abs/2608.04289](#)

02

Remember, Verify, or Ask? (MCB)
[arXiv 2608.19564 · 2026-08-20 · https://arxiv.org/abs/2608.19564](#)

03

AgentAbstain
[arXiv 2607.10059 · 2026-07-11 · https://arxiv.org/abs/2607.10059](#)

04

Router-Mem
[arXiv 2608.01285 · 2026-08-02 · https://arxiv.org/abs/2608.01285](#)

05

InfMem
[arXiv 2602.02704 · COLM 2026 · https://arxiv.org/abs/2602.02704](#)

06

MemSyco-Bench
[arXiv 2607.01071 · 2026-07-01 · https://arxiv.org/abs/2607.01071](#)

07

SURE-RAG
[arXiv 2605.03534 · 2026-05-05 · https://arxiv.org/abs/2605.03534](#)

08

Memory as a Controlled Process
[arXiv 2607.13591 · 2026-07-15 · https://arxiv.org/abs/2607.13591](#)

09

Oblivion
[arXiv 2604.00131 · EMNLP 2026 · https://arxiv.org/abs/2604.00131](#)

10

KnowU-Bench
[arXiv 2604.08455 · 2026-04-09 · https://arxiv.org/abs/2604.08455](#)

11

When2Tool
[arXiv 2605.09252 · 2026-05-10 · https://arxiv.org/abs/2605.09252](#)

12

Calibrate-Then-Act
[arXiv 2602.16699 · 2026-02-18 · https://arxiv.org/abs/2602.16699](#)

13

MetaMem
[arXiv 2602.11182 · 2026-01-27 · https://arxiv.org/abs/2602.11182](#)

14

Decision-Aware Memory Cards
[arXiv 2606.08151 · 2026-06-06 · https://arxiv.org/abs/2606.08151](#)