

MetaMemBench

面向 Agentic Memory 的 记忆监控与控制策略诊断基准

Evaluating Monitoring and Control of Agent Memory under Uncertainty

核心问题

当前记忆是否足以支撑行动？若不足，Agent 应该继续搜索、向用户澄清，还是拒绝承诺？

从“检索到什么”
走向“何时可以行动”

01 Sufficiency

充分性判断

02 Control

搜 / 问 / 做 / 拒绝

03 Counterfactual

反事实动作翻转

04 Diagnosis

分解失败来源

先给结论：不要只做“动态 StratMem”

推荐主线

MetaMemBench

评测 Agent 是否知道当前记忆“够不够”，并在承诺行动前选择正确的控制动作。

diagnostic

counterfactual

sufficiency-aware

control-before-commitment

暂时放弃的表述

Dynamic Strategic Memory

多轮化本身容易被视为 StratMem-Bench 的自然扩展。

“首个 memory control”

AgeMem、MemCon、MemSearcher 已学习何时与如何调用 memory。

真正可争取的贡献

统一、可诊断、可执行的 memory-control 评测协议。

它属于 Agentic Memory, 但与 RAG / Context Engineering 交叉

Agent Memory

持久、跨 session、随交互演化

Agentic RAG

主动检索、查询改写、停止策略

OUR POSITION

Persistent memory



Monitor sufficiency



Control next action



Verify downstream consequence

LLM Memory

参数 / KV / 长上下文机制

Context Engineering

工具、预算与临时上下文组织

边界条件：必须同时保留 persistent、interaction-derived memory, Agent-controlled access, 以及可验证的行动后果。

已有工作如何一步步逼近“记忆控制”



现状：方法已经在学习 memory action；评测却仍主要停留在候选池选择或最终任务成功。

StratMem-Bench: 重要起点, 但它问的是“用哪些”

657

INSTANCES

8.79

AVG. POOL

< 50%

MUST+NICE SMC

输入

固定候选池



must

nice

irrelevant

它已经解决

query-conditioned 记忆角色不是固定属性; 模型需要使用必要记忆、选择性利用支持记忆, 并抑制无关记忆。

它没有要求 Agent 做什么

- 判断当前 packet 是否足以安全行动
- 主动搜索缺失记忆或改写 query
- 区分“store 里有”与“只能问用户”
- 在 EXECUTE / ASK / ABSTAIN 间控制承诺
- 让动作进入环境并验证后果

StratMem asks which memories should appear; MetaMemBench asks whether memory can justify acting at all.

最邻近工作：各自解决了一块，但没有统一诊断控制决策

工作	已经解决	仍留下的可验证问题
Mem2ActBench	长记忆 → 工具参数	离线 tool-call；搜索/澄清不是正式动作
MemoryArena	跨 session 环境闭环	只有 task success/progress，缺 decision-point gold
AMemGym	on-policy 长程对话	动态环境已有；memory-control 不是独立评测单元
MemOps	remember/update/forget/reflect	评 lifecycle，不评 query-time evidence sufficiency
TANGLE / StateMem	冲突与状态更新	覆盖特定失效类型，不覆盖完整控制状态空间
AgeMem	工具化 memory operation + RL	证明可学控制；缺独立统一的动作诊断协议
MemCon	Memory MDP + 在线策略	依赖终局反馈，难解释 monitor/action 为何对错

MetaMemBench 不替代这些任务，而是提供跨系统的 monitor / control / outcome / cost 诊断层。

现有评测从两侧逼近，却漏掉了“行动前控制”

固定候选池评测

看得见全部候选
能评“选哪些”
不能评搜索、澄清、停止与拒绝



缺失的评测层

Memory-state
monitoring

+

next-action control



端到端任务评测

有真实行动后果
但最终成功混合了检索、控制、执行
甚至可能靠猜测“碰巧成功”

RESEARCH GAP

缺少一种受控、可诊断的评测协议，用来测试 Agent 是否能判断当前记忆状态的充分性，并在承诺回答或执行动作之前，选择合适的下一步控制动作。

正式问题：从记忆状态 z_t 映射到可接受控制动作

六类隐藏状态

NO MEMORY NEEDED

无需历史即可安全执行

SUFFICIENT

已有最小充分证据闭包

RETRIEVABLE MISSING

缺失证据仍在 store 中

USER-ONLY MISSING

只能由用户补充约束

STALE / CONFLICT

旧值或冲突仍可解析

IRREDUCIBLE

现有来源无法唯一支持行动

四种外部动作

SEARCH_MEMORY

继续检索 / 改写 query

ASK_USER

询问缺失 slot

EXECUTE

回答或调用工具，并提交 evidence IDs

ABSTAIN

拒绝不受支持的承诺

关键方法学约束

gold 只能依据 Agent 当时可见的信息；不确定时用 admissible action set + cost/regret，而不是强迫唯一动作。

真正难点不是把对话变长，而是把“可行动性”标对、测准

01 充分性 $\neq$ 相关性

单条都相关，不代表组合已经覆盖全部约束；旧偏好也可能高度相似却有害。

02 部分可观测下的动作 gold

从当前 packet 未必能知道 store 是否仍有答案；SEARCH 与 ASK 可能都合理。

03 控制失败的因果归因

最终错误可能来自 monitor、retriever、controller 或 executor，单一成功率无法区分。

04 风险与成本同时校准

过早执行有风险；反复搜索、频繁追问也会伤害效率与用户体验。

05 数据有效性与捷径控制

需要 symbolic world、反事实配对、base-task 分割、表述改写与 human challenge split, 防止模型只记模板。

三个递进 Track：先隔离能力，再开放控制，最后验证行动



两个核心任务域


Personalized Tool Execution

日历 / 出行 / 购物 / 提醒 / 文件操作；gold 为结构化 tool call 与环境终态。

Progressive Search and Planning

跨 session 约束与反馈；gold 为 evidence closure、规划约束与最终状态。

数据构造：先建可执行世界，再生成自然语言




同一 base task 的六种受控变体



核心观察不是平均 accuracy，而是 decisive memory 插入/移除后，控制动作是否发生正确翻转。

拒绝用一个总分掩盖系统差异：四层指标分别报告



同样的最终成功率，可能对应完全不同的记忆控制质量与用户成本。

Baseline 不是越多越好，而是要能定位瓶颈

SANITY

NoMemory · AlwaysSearch · AlwaysAsk · AlwaysExecute · confidence threshold

RETRIEVAL

BM25 · dense · hybrid · Retrieve-Once@k · FullHistory

MEMORY SYSTEM

Mem0 / LangMem · A-MEM · StratMem-style reader · StateMem wrapper

AGENTIC CONTROL

Self-RAG-style router · MemSearcher · Memory-R1 · AgeMem · MemCon

ORACLE DECOMPOSITION

OraclePacket / OracleMonitor / OracleRetriever / OracleController / OracleAll

公平比较约束

固定 backbone、tool schema、token、搜索轮数与可见 memory source。

实验设计：先证明 benchmark 有效，再比较方法

E0 Validity

能力梯度 / 人工一致率

E1 Main

模型与系统主表

E2 Decomposition

四种 oracle 干预

E3 Counterfactual

六变体动作翻转

E4 Calibration

risk-coverage / ECE

E5 Budget

memory / top-k / rounds / size


E6 Generalization

跨任务域迁移

可证伪假设

- H1 最终正确率会高估 memory control，因为存在猜测与不合法证据。
- H2 强模型在 USER_ONLY / IRREDUCIBLE 上仍会过早承诺。
- H3 固定 retrieve-once 帮助 hidden-in-store，却伤害 no-memory 与干扰场景。
- H4 MemCon 可能改善 success-cost，但不一定校准 sufficiency。

Benchmark 暴露失败后，再做 MetaMem Controller



设计原则 只有 verifier 通过，或 policy 明确接受风险时，Execution Gate 才允许最终行动。

目标：把“看见相关记忆”升级为“形成最小充分证据闭包后再行动”。

排序学习放在哪里：逐条判断、相对选择、集合闭包

Pointwise

预测单条 memory 的相关性、时效性、authority 与 slot coverage。

Pairwise

在 decisive evidence 与 hard negative 之间学习相对效用，适合下一条证据 / 动作选择。

Listwise / Setwise

选择能闭合全部需求的最小证据集合，处理“每条都相关但组合仍不充分”。

训练路线



最终 reward Exact task success + admissible action + evidence closure – search/clarify cost – premature/unsupported action

第一版不训练独立 GRM：结构化 gold 与环境执行已提供 RLVR 风格信号。

最小闭环：1-2 周判断这个问题是否真的成立

20 × 6

BASE TASKS ×
VARIANTS
120 episodes

1

DETERMINISTIC TOOL

calendar / travel

4

SANITY BASELINES

Execute / Retrieve / Full /
Oracle

1-2

WEEKS

without training

4×4090

AVAILABLE


7B/8B LoRA-ready

Go / No-Go Gate

- OracleAll 接近可解上界，NoMemory 与 OraclePacket 有显著差距。
- 至少两个 baseline 在 premature execution / unnecessary search 上呈现不同 trade-off。
- 强模型的 counterfactual action flip 不能接近满分；FullHistory 不能轻易饱和。
- 人工 state / admissible action 一致率足够高，且 ≥80% 主指标可规则化计算。

GPU 不是核心壁垒：主要资产是 generator、simulator、evaluator 与 baseline harness。

10 周执行路线：每一阶段都有可停止的检查点



关键决策点：W3 pilot gate → W7 method need → W9 是否支撑“通用 agentic memory control”论点。

预期贡献与论文主线

01 **Problem** 定义 memory monitoring and control before commitment.

02 **Benchmark** gold state、evidence closure、admissible action 与 executable outcome.

03 **Protocol** Monitor / Control / Outcome / Cost + oracle decomposition.

04 **Evidence** 系统比较 long-context、RAG、memory backend 与 agentic controllers.

Take-home

Agentic memory 的关键不只是“能存、能取”，而是：

**知道何时已经足够，
何时还应继续找，
何时必须向人询问，
何时应该停止承诺。**

BENCHMARK FIRST

核心参考文献

完整调研与问题推导见配套 proposal 文档

01

Memory in the Age of AI Agents
[Survey · arXiv 2512.13564 · https://arxiv.org/abs/2512.13564](#)

02

StratMem-Bench
[ACL 2026 Main · Long Paper · https://aclanthology.org/2026.acl-long.1491/](#)

03

Mem2ActBench
[ACL 2026 Main · Long Paper · https://aclanthology.org/2026.acl-long.370/](#)

04

MemoryArena
[arXiv 2602.16313 · https://arxiv.org/abs/2602.16313](#)

05

AMemGym
[ICLR 2026 · https://arxiv.org/abs/2603.01966](#)

06

MemOps
[arXiv 2607.12893 · https://arxiv.org/abs/2607.12893](#)

07

MemTrace
[arXiv 2605.28732 · https://arxiv.org/abs/2605.28732](#)

08

TANGLE
[arXiv 2608.13921 · https://arxiv.org/abs/2608.13921](#)

09

StateMemBench
[arXiv 2608.19652 · https://arxiv.org/abs/2608.19652](#)

10

AgeMem
[ACL 2026 Main · Long Paper · https://aclanthology.org/2026.acl-long.981/](#)

11

Memory as a Controlled Process (MemCon)
[arXiv 2607.13591 · https://arxiv.org/abs/2607.13591](#)

12

StreamMemBench
[arXiv 2606.14571 · https://arxiv.org/abs/2606.14571](#)

13

CIMemories
[ICLR 2026 · https://arxiv.org/abs/2511.14937](#)

14

Decision-Aware Memory Cards / CICL
[arXiv 2606.08151 · https://arxiv.org/abs/2606.08151](#)