

Agent Memory 入门综述

定义、系统、方法、评测与发展趋势

从“保存聊天记录”到“管理可持续的 Agent 状态”

面向初学者 · 文献核验截止 2026-09-08

Knowledge Science and Engineering Laboratory



看完这份综述，你应该能回答五个问题



1

为什么需要

LLM 有上下文，为何还需要长期记忆？

2

记忆是什么

哪些状态属于 Agent Memory，哪些只是 RAG？

3

系统怎么做

如何形成、组织、检索、使用、更新与治理？

4

怎样评测

从事实召回到工具行动，指标如何演化？

5

未来往哪走

学习型策略、在线交互、可信与成本为何重要？

主线：Why → What → How → Evaluation → Future



为什么普通 LLM 不等于有记忆的 Agent



Session A: 过去

- 用户：我对花生过敏
- 模型：收到
- 会话结束后，信息可能离开当前上下文



Session B: 未来

- 用户：帮我订晚餐
- 当前问题没有再次说明过敏信息
- Agent 仍需恢复并使用历史约束



真正的挑战

- 写入：值得长期保存吗？
- 读取：现在仍有效吗？
- 行动：证据足够下单吗？
- 更新：新信息与旧信息冲突怎么办？

上下文解决“现在看见什么”；Memory 解决“历史怎样成为未来可用状态”。



Agent Memory 的工作定义



Agent Memory 是由历史交互形成、跨当前上下文或会话持续存在，并在未来推理、规划和行动中被选择性读写与更新的状态。

持久性 Persistence

- 跨 turn / session / task 保留
- 不只依赖当前 prompt
- 状态可以有版本和生命周期

能动性 Agency

- 决定写、读、更新与遗忘
- 规则、LLM 或 learned policy
- 可主动验证或抑制记忆


行为后果 Consequence

- 改变回答、计划和工具调用
- 影响未来状态与经验
- 正确与错误都可能累积

数据库里有历史文本，不自动等于 **Agent** 拥有了可用的长期记忆。



四个基本对象：Item、State、System、Policy



$$M_t = U(M_{t-1}, H_t; \pi^M)$$

历史 H 经过记忆策略 π^M 更新为下一时刻的持久状态 M

研究对象从“存了哪些文本”扩展为“状态怎样形成、变化并控制行为”。




不要混淆：Memory、RAG、长上下文与上下文工程



概念	核心对象	时间尺度	持续更新	主要目标
长上下文	当前 token 序列	单次调用	否	读得更多
RAG	外部文档库	单次任务	通常否	找外部知识
Agentic RAG	主动搜索过程	多步任务	可选	规划检索
Context Engineering	当前上下文配置	当前任务	临时	编排资源
Agent Memory	历史形成的状态	跨会话/任务	是	持续学习与行动
LLM Memory	参数、激活、KV	推理到模型生命周期	视机制	容量与效率

判断题：删除当前 query 后，信息是否仍因过去交互而存在并继续演化？




Memory 里有什么？

类型、形式与生命周期

Knowledge Science and Engineering Laboratory



按功能分类：Agent 到底记住什么



事实 / 语义

- 用户事实、偏好、环境关系
- 回答：是什么

情景

- 带时间、参与者和结果的经历
- 回答：发生过什么

经验 / 反思

- 失败教训、注意事项、策略
- 回答：以后如何改进

程序 / 技能

- 计划、工具链、代码、工作流
- 回答：如何做

工作记忆

- 当前任务中间状态与目标
- 回答：现在做到哪里

前瞻记忆

- 未来条件触发的延迟意图
- 回答：何时再做

同一系统常同时保存事实、经历和技能；不同类型需要不同更新与评测。



按形式分类：记忆以什么结构存在



形式	典型实现	优势	主要局限
原始轨迹	完整对话、工具日志	保真、可审计	成本高、噪声多
文本条目	事实、摘要、反思	可读、易接入	结构和限定条件易丢
向量索引	Embedding + Top-k	成熟、快速	相似不等于适用
结构 / 图	JSON、事件图、时间图	关系清晰、可追踪	建图和维护复杂
层次记忆	短期 / 中期 / 长期	效率与范围平衡	跨层一致性困难
参数 / 隐式	微调、LoRA、memory token	调用紧凑	难解释、删除与更新
混合系统	原文 + 索引 + 图 + 技能	能力完整	故障归因更难

结构没有绝对优劣：任务所需关系、更新频率和审计要求决定选择。




完整生命周期：从历史事件到未来行为



历史交互 $H_{1:t}$

持续状态 M_t


未来行为与反馈



任一阶段都可能失败，最终准确率无法告诉我们错误发生在哪里。



一套最小可运行的 Memory Agent



反馈与更新

最低日志要求

- 写入前事件 | 写入后状态 | 检索候选 | 可见证据 | 最终行动 | 环境反馈 | 更新记录

先把生命周期记录清楚，再讨论复杂模型；否则无法区分写入、检索和使用错误。



方法如何演化？

从存储记录到学习 Memory policy

Knowledge Science and Engineering Laboratory



发展时间线：四个阶段



外部记忆成型

- Generative Agents
- Reflexion / Voyager
- MemGPT

长期对话评测

- LoCoMo
- 多会话与时间推理
- 图检索

组织与经验复用

- LongMemEval / A-MEM
- AWM / MemoryOS
- 效率与结构

策略、行动、治理

- AgeMem / Memory-R1
- StratMem / Mem2Act
- 可信与成本

2023

2024

2025

2026

主线：Storage → Reflection → Experience → Learned control and governance



2023：四种奠基思路



Generative Agents

- 保存自然语言经历
- 按相关性、时近性和重要性检索
- 反思形成高层认知
- 记忆服务计划和社会行为

Reflexion

- 把环境反馈转为语言反思
- 写入 **episodic buffer**
- 不更新模型参数
- 跨 **trial** 改进行为

Voyager

- 开放式具身探索
- 保存可执行技能代码
- 组合和复用技能
- 以环境反馈持续改进

MemGPT

- 类操作系统分层内存
- 有限上下文与外存调度
- 用 **interrupt** 管理控制流
- 支持跨会话对话

共同贡献：让 **Agent** 能在模型参数不变的情况下积累跨任务状态与经验。



2024–2025：从“能否找回”走向“如何组织与复用”



评测基础

- LoCoMo: 超长多会话对话
- LongMemEval: 抽取、跨会话、时间、更新、拒答
- 问题从短对话扩大到持续交互

动态组织

- A-MEM: 动态索引和链接
- 新记忆可更新旧条目属性
- 从平坦 Top-k 走向关联网络

经验复用

- AWM: 从轨迹归纳 workflow
- MemoryOS: 多层存储与管理
- 从“发生了什么”走向“以后怎么做”

这一阶段的关键词：long-term evaluation、organization、workflow、efficiency。




2026: Memory operation 成为可学习的 Agent 行为



过去：固定规则

现在：自主操作

进一步：学习策略



关键变化：Memory 不再只是后端组件，而成为 Agent policy 的动作空间。



六类常见架构：选择取决于任务，而非流行度



家族	做法	优势	核心风险
Full history	保留全部或最近历史	简单、保真	成本与干扰
Retrieval	切分 + 索引 + Top-k	成熟、快速	相似不等于适用
Hierarchical	近期细节 + 长期摘要	平衡范围和效率	压缩失真
Graph	实体 / 事件 / 时间关系	多跳与追踪	构建维护复杂
Experience / Skill	反思、案例、工作流	跨任务复用	负迁移
Parametric / Latent	参数或隐式状态	调用紧凑	难审计与删除
Hybrid	原文 + 索引 + 图 + 技能	能力完整	故障归因困难

现代系统通常是混合架构；真正困难的是跨组件一致性与可诊断性。



Formation 与 Organization: 怎样把历史变成记忆



写入策略

- 全量保存
- 事实 / 偏好抽取
- 摘要与反思
- novelty / importance / utility
- ADD / UPDATE / DELETE / NOOP

组织与元数据

- Embedding、关键词与标签
- 实体、时间与事件关系
- 来源 provenance
- 权限 authority / scope
- 版本与 supersession

主要失败

- 漏写重要信息
- 把推测写成事实
- 临时要求变成永久偏好
- 摘要丢失否定和例外
- 错误链接与过度抽象

写入质量决定后续上限：不存在或被错误抽象的证据，检索器无法恢复。



检索失败

- 正确记忆未进入候选; 旧版本或相似噪声排在前面

使用失败

- 正确证据已可见, 但 Agent 忽略、误解或过早行动

必须分别记录 **retrieved evidence** 与实际行为, 才能区分 **recall** 和 **utilization**。



Evolution 与 Governance: 让记忆长期可用且可控



状态演化

- 覆盖旧值
- 保留全部版本
- 记录 **supersede** 关系
- 冲突未决时继续验证
- 压缩、合并与遗忘

治理字段

- 来源：谁说的？
- 权威：能否支持该动作？
- 作用域：适用于谁和哪里？
- 时效：现在仍有效吗？
- 审计：影响了哪个行为？

长期风险

- 旧值残留与冲突
- 来源在摘要中消失
- 用户或项目串扰
- 错误经验反复重放
- 敏感信息无法撤销


“过去真实” 不等于 “现在有效” ； “曾被写入” 也不等于 “有权影响行动” 。



怎样评价 Memory?

从事实召回到行动、成本与可信

Knowledge Science and Engineering Laboratory



问题从“记住了吗”变成“记忆是否恰当地改变了当前与未来行为”。



代表性 Benchmark：各自测什么



Benchmark	出处	主要能力	边界
LoCoMo	ACL 2024	多会话回忆、时间、总结	偏问答 / 生成
LongMemEval	ICLR 2025	抽取、跨会话、更新、拒答	非完整行动闭环
MemoryAgentBench	ICLR 2026	检索、TTL、LRU、遗忘	以 chunk 为主
AMemGym	ICLR 2026	on-policy write/read/use	任务域与用户模拟受限
StratMem-Bench	ACL 2026	必须 / 可选 / 无关记忆	候选已给定
Mem2ActBench	ACL 2026	工具选择、参数落地	主要是离线行动生成
MemoryArena	arXiv 2026	记忆获取与环境行动	预印本，协议演化中

没有一个分数能代表全部 **Memory** 能力；应按任务所需生命周期选择评测。



六层指标：不要只看最终准确率



内容

- 写入 P/R、事实一致性、来源保留

检索

- Recall@k、MRR、证据覆盖、预算

使用

- 答案、工具、参数、证据引用

演化

- 更新、失效、冲突、未来复发

效率

- Token、调用、延迟、存储增长

治理

- 权限、泄露、污染、审计、撤销

最终答案错误可能来自写入、检索、使用或更新；指标必须支持阶段归因。



常见失败模式：Memory 也会制造错误



漏写 / 幻觉写入

- 重要信息未保存，或推测被写成事实

检索错位

- 相似但过期、跨用户或不同条件的经验抢占

召回后不用

- 证据可见，但模型仍按旧计划或参数先验行动

过度使用 / 锚定

- 旧经验压制新证据和探索分支

压缩与版本失真

- 否定、例外、来源、时间和权限被丢失


错误传播

- 一次错误被保存并在未来相似任务中重放

Memory 的价值来自跨时间复用；它的风险也会跨时间累积。



更多 Memory 为什么不一定更好



长期净效用

$$U(M) = \begin{aligned} &\text{任务收益} \\ &- \text{成本} \\ &- \text{干扰} \\ &- \text{风险} \end{aligned}$$



Memory 太少

- 关键信息漏失
- 重复探索
- 个性化和连续性不足
- 历史反馈无法复用

Memory 太多

- 检索和 token 成本上升
- 旧版本与噪声抢占
- 经验锚定和探索收缩
- 隐私与污染面扩大

现代目标不是“存得最多”，而是在任务、成本和风险之间获得更高净效用。



公平比较 Memory system, 需要控制什么



1

Backbone

固定基础模型与解码参数

2

Ingestion

报告切分、摘要和原文保留

3

Retrieval

配平 Top-k、token 与调用预算

4

Exposure

记录真正进入上下文的证据

5

Evaluator

工具用程序评分, 文本再用 judge

6

Unit

按用户 / 事件 / family / episode 统计

Embedding、chunk、Top-k 和 judge 的差异, 可能比方法名称更影响排行榜。



未来往哪里走？

方法、评测与系统目标的共同变化

Knowledge Science and Engineering Laboratory



六条发展趋势



自主操作

- 固定 pipeline → Agent 调用 memory tools

学习策略

- Prompt / rule → SFT / preference / RL

经验与技能

- 记事实 → 复用 workflow 和可执行技能

条件化使用

- Always-on/off → 按状态控制依赖

在线评测

- 固定历史 → 行为改变未来 Memory

可信与成本

- 单一准确率 → 多目标长期净效用

竞争焦点正在从“记忆容量”转向“记忆策略是否可靠、经济且可治理”。



仍然开放的研究问题




学习与决策

- 写入时看不到未来任务，如何估计长期价值？
- 何时依赖经验，何时保留探索并重新验证？
- 多条记忆共同支持行动时，如何评价组合贡献？
- 怎样保护低频但高后果的约束？

可信与评测

- 压缩后如何保留来源、时间、否定和权限？
- 多 Agent 共享记忆时，如何隔离身份与责任？
- 错误已经造成外部后果后，怎样最小化修复？
- 排行榜对 chunk、embedding、预算和 judge 稳定吗？


开放问题不等于新颖性主张：仍需核查同期工作并先做可证伪 **pilot**。



先建立可观察的系统，再训练模块；否则高分也无法解释 **Memory** 为什么有效。



推荐阅读路径：四组论文建立完整认知



阅读顺序：先理解系统对象，再看 **Benchmark**，最后看学习策略与治理。



总结：用五句话记住 Agent Memory



1

定义

由历史形成、跨会话持续、受策略管理并影响未来行为

2

系统

形成、组织、检索、使用、更新和治理缺一不可

3

方法

从存储与 Top-k 走向经验抽象和 learned memory policy

4

评测

从事实召回走向行动、生命周期、成本和可信

5

原则

更多 Memory 不必然更好；长期净效用才是目标

Memory 不只是存储组件，而是 **Agent** 的持续状态、学习介质和责任边界。



参考文献（一）：综述与奠基工作



[1] Hu et al. Memory in the Age of AI Agents. arXiv:2512.13564.

[6] Wang et al. Voyager. arXiv:2305.16291.

[2] Zhang et al. Rethinking Memory in AI. arXiv:2505.00675.

[7] Packer et al. MemGPT. arXiv:2310.08560.

[3] Luo et al. From Storage to Experience. ACL Findings 2026.

[8] Maharana et al. LoCoMo. ACL Long 2024.

[4] Park et al. Generative Agents. UIST / arXiv 2023.

[9] Wu et al. LongMemEval. ICLR 2025.

[5] Shinn et al. Reflexion. NeurIPS Main 2023.

[10] Tan et al. MemBench. ACL Findings 2025.



参考文献（二）：代表性方法



[1] Xu et al. A-MEM. NeurIPS Main 2025.

[2] Wang et al. Agent Workflow Memory. ICML 2025.

[3] Kang et al. MemoryOS. EMNLP Main 2025.

[4] Ong et al. THEANINE. NAACL Long 2025.

[5] Yu et al. Agentic Memory (AgeMem). ACL Long 2026.

[6] Yan et al. Memory-R1. ACL Long 2026.

[7] Zhang et al. LightMem. ACL Long 2026.

[8] Jiang et al. MAGMA. ACL Long 2026.

[9] Wu et al. GAM. ACL Long 2026.

[10] Huang et al. Controllable Memory Usage. ACL Long 2026.



参考文献（三）：评测、行动与风险



[1] Wu et al. StratMem-Bench. ACL Long 2026.

[6] Xiong et al. How Memory Management Impacts LLM Agents. ACL Long 2026.

[2] Shen et al. Mem2ActBench. ACL Long 2026.

[7] Locomo-Plus. ACL Long 2026.

[3] AMemGym. ICLR 2026.


[8] From Recall to Forgetting (Memora). ACL Findings 2026.

[4] MemoryAgentBench. ICLR 2026.

[9] Demystify the Role of Memory in MLE Agents. ACL Findings 2026.

[5] MemoryArena. arXiv:2602.16313.

[10] Branch-and-Browse. ACL Long 2026.



谢谢！

Agent Memory: 从历史记录到可持续、可行动、可治理的状态

Knowledge Science and Engineering Laboratory